M2ISE

Université Paris 8 - Vincennes à Saint-Denis

Master Informatique des Systèmes Embarqués

Memoire de projet tuteuré

Fakhri YAHIAOUI - Roman BOURSIER

Date de soutenance : le 09/06/2020

Tuteur – Université : Farès BELHADJ

Résumé

A faire en dernier ...

Remerciements

Idem ...

Table des matières

Introduction

Dans le cadre de notre projet de fin d'étude, nous souhaitons utiliser un modèle de Deep Learning, afin de produire un moteur de rendu capable d'adopter une stylisation « type » telle que la peinture chinoise. Dans un premier temps, il s'agira de proposer un modèle d'abstraction des peintures sélectionnées comme base d'apprentissage et d'utiliser le couple « peinture originale » / « abstraction » pour l'entraînement. Par la suite, un moteur de rendu d'abstractions sera connecté au réseau profond qui produira une peinture sur la base de l'abstraction.

Le modèle généré devra d'une part adopter la stylisation retenue mais aussi interpréter l'abstraction d'origine.

0.1 Problématique

La "traduction image-image" (Image-to-image translation) permet d'apprendre le mapping entre une image d'entrée et de sortie. En Figure 1, nous testons la génération d'un paysage à partir d'un croquis simple. En Figure 2, c'est un échec.

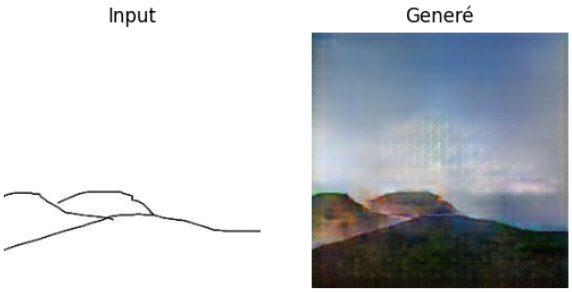

FIGURE 1 – Test du framework pix2pix [IZZE16] sur notre dataset composé de photos de paysages, labellisées en appliquant un filtre Canny [Can86] sur chacune d'elles.

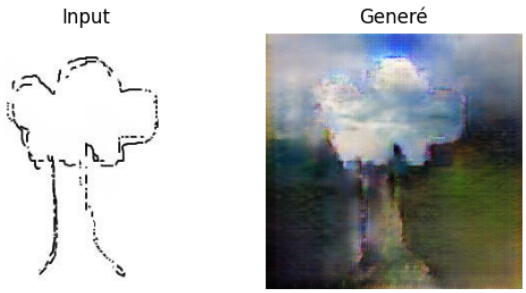

FIGURE 2 – Utilisation du même modèle avec une abstraction d'arbre

Comme évoqué dans [SPS+18] les algorithmes du type "traduction image-image" se basent essentiellement sur la corrélation d'une image à l'autre, et relève d'un apprentissage supervisé. Le rendu en Figure 2 s'explique par la nature du dataset et par la distance importante qui sépare une abstraction d'une photo.

En Figure 3 nous avons demandé à plusieurs personnes de dessiner un paysage composé de montagnes et d'arbres, éléments courant de la peinture chinoise. Ces dessins sont des abstractions, que nous souhaitons traduire en peintures chinoises.

(a) (b) (c)

FIGURE 3 – Dessin de paysages réalisés par des personnes différentes. On note que les niveaux d'informations sont plus ou moins élevés. Le dessin (b) est très abstrait tandis que nous observons plus de détails pour (a) .

Chapitre 1

Etat de l'art

Nous présentons dans un premier temps les GANs qui sont au coeur de notre problématique. En un second lieu, nous étudions différents modèles existants basés sur les GANs conditionnels. Nous évoquons aussi, de manière plus succincte, des travaux liés à notre sujet mais n'utilisant pas les réseaux de neurones afin de pouvoir identifier les avantages et inconvénients des deux approches. Nous terminons par une liste des datasets utiles à notre sujet.

1.1 Généralités sur les GANs

"Les GANs (en anglais generative adversarial networks) sont une classe d'algorithmes d'apprentissage non-supervisé. Ces algorithmes ont été introduits dès 2014 par Goodfellow et permettent de générer des images avec un fort degré de réalisme." [Wik20]

Un générateur fabrique des données et les soumets au discriminateur dont le but est d'évaluer leurs degré de crédibilité.

Le générateur $G(z, \theta_1)$ représente un réseau de neurones capable de mapper du bruit z vers l'espace désiré x. Le discriminateur $D(z, \theta_2)$ retourne la probabilité dans l'intervalle $[0, 1]$ que x vient du dataset original. θ_i représente les poids définis par chacun des modèles. Le générateur tente de maximiser la probabilité que les données x, soient classifiées comme appartenant au dataset d'origine et inversement, le discriminateur minimise la probabilité que de fausses images appartiennent au dataset d'origine.

Il existe aujourd'hui une très grande variété de travaux de recherches basés les GANs (BCGAN, AmbientGAN, ORGAN, Perceptual GAN). Le dépôt "The GANs Zoo" [hin18] référençait déjà en 2018 plus de 502 noms de GANs différents !

1.2 CGANs et traduction d'image

Les GANs conditionnels ajoutent une information supplémentaire y, partagée par le discriminateur et le générateur. Grâce aux cGANs il est possible de générer des images réalistes basées sur des labels de classes, des textes ou des images.

1.2.1 Pix2Pix

[GEB15] nous montre en quoi les cGANs peuvent permettre de résoudre efficacement les problèmes de traductions d'images et propose un framework applicable à n'importe quel domaine.

1.2.2 GauGan

[PLWZ19] permet de générer des paysages réalistes basés sur des masques de segmentation sémantiques. Les auteurs introduisent la "normalisation conditionnel" ou "adaptative", permettant de prendre en compte notamment les informations spatiales. Les couches de normalisations ont tendances à faire perdre de l'information contenu dans les masques sémantiques d'entrées car ils ne dépendent pas de données externes.

(a) Input - masques de segmentation sémantiques

(b) Output

FIGURE 1.1 – Test de rendu de paysage à partir de l'application Gaugan : http ://nvidia-research-mingyuliu.com/gaugan/

1.2.3 CycleGan

CycleGan [ZPIE17], présente une approche pour la traduction d'une image d'un domaine source vers un domaine cible lorsque le dataset n'est pas apparié.

Le modèle possède deux générateurs $G : X \to Y$ et un second $F : Y \to X$ ainsi que deux discriminateurs D_Y and D_X

Les auteurs nous explique que si nous pouvons passer du domaine X vers le domaine Y et vice versa, alors le résultat final devrait être identique à l'entrée initiale X

1.2.4 Transfert de style neuronal

Introduit par Leon A. Gatys [GEB15] le TDN consiste à transférer un style à partir d'une image de référence vers une image de contenu. L'objectif est de transformer l'image d'entrée (bruit) en minimisant la distance avec l'image de contenu et avec l'image de style. On obtient alors par rétropagation, une image qui correspond au contenu de l'image d'origine et au style souhaitée.

L'avantage de cette technique est quelle ne nécessite pas de dataset, seulement deux images sont nécessaires.

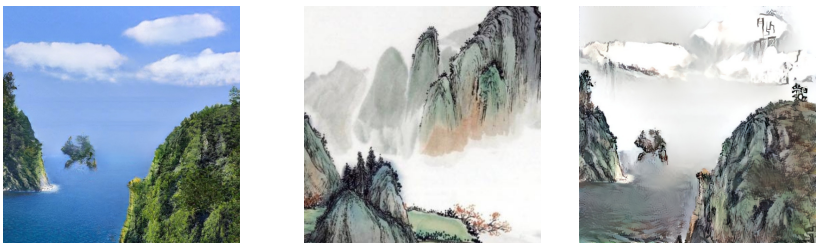

(a) Image de contenu (b) Image de style (c) Résultat

FIGURE 1.2 – Test de transfert de style réalisé à partir de la figure 1.3(b)

1.2.5 Learning to Sketch

[SPS+18] présente une méthode permettant de transformer une photo en croquis, en essayant d'imiter la façon de faire d'un humain. Le modèle est capable de réaliser le croquis séquentiellement, c'est à dire trait par trait. Les auteurs proposent de résoudre le problème des styles subjectifs et variés des dessins humain en utilisant un modèle hybride supervisé/non-supervisé. L'objectif étant de palier "au signal de supervision faible et bruyant" induit par l'écart important entre un croquis et sa photo correspondante.

L'architecture est décomposé en 4 sous-modèles contenants chacun leur propres sous-réseaux d'encodeurs et de décodeurs. Deux réseaux supervisés traduisent respectivement une photo en croquis $D(E(photo)) \rightarrow sketch$ et un croquis en photo $(D(E(sketch)) \rightarrow photo)$. Deux autres réseaux non-supervisés se chargent de la reconstruction. $D(E(photo)) \rightarrow photo$ et

$D(E(sketch)) \rightarrow sketch$

1.2.6 Sketching : Inferring Contour Drawings from Images

[LLM+19] propose une nouvelle approche concernant la détection des contours dans une image. L'article montre que les solutions traditionnelles comme Canny [Can86] , captent uniquement les signaux de haute fréquence dans l'image sans la comprendre. Les auteurs ont collecté un dataset de 5000 pairs "croquis humain/photos", crée manuellement via la plateforme de crowdsourcing "Amazon Mechanical Turk". En effet aucun dataset existant ne convenait (nombre d'éléments dans l'image, limites internes manquantes, le contenu non reconnaissable, les zones ombrées vides etc ..).

Ce modèle également du type "traduction image-image", permet d'avoir plusieurs labels différents pour la même photo, donc plusieurs interprétations différentes.

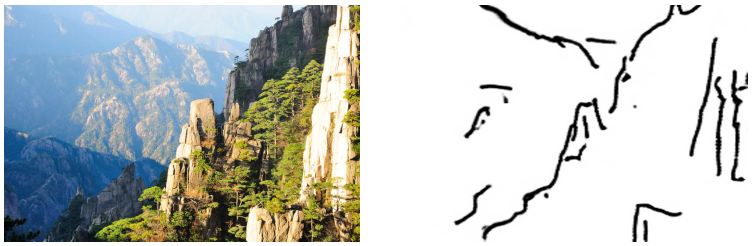

(a) Input (b) Output

FIGURE 1.3 – Test du modèle pré-entraîné sur une photo de paysage

Chapitre 2

Proposition de solution

2.1 Datasets

Malgrès nos recherches, nous n'avons pas pu trouver de dataset correspondant exactement à nos besoins, c'est-à-dire des paires d'abstraction/peinture chinoise.Pour les croquis, les plus grosse bases existantes sont TU-Berlin [EHA12], Sketchy [SBHH16] et Quickdraw. Après plusieurs essais, nous avons décidé d'abandonner leur utilisations car il s'agit le plus souvent d'objets isolés et non appairés à une image réaliste. Pour la peinture chinoise, nous avons récupérer un premier dataset de 5000 images ([ych18]) et scrappé des plateformes comme google/baidu et pinterest.

Au final notre dataset est composé de 624 peinture de paysage chinois, répartis en 90/10, nous l'avons réduit essentiellement pour des raisons de temps d'apprentissage trop long. Chaque images sera par suite redimensionné et recadrées au format 256x256.

2.2 Modèle

Afin de résoudre le problème de la distance trop importante qui sépare un croquis d'une peinture, nous proposons de découper l'apprentissage en deux étapes. La première consiste à traduire un croquis en dessin détaillé et la seconde d'un dessin détaillé vers la peinture. Notre proposition se base sur deux cGan de type "image-image", entraîné sur deux datasets appairées.

L'implémentation utilise le framework Keras et se base sur l'architecture pix2pix[].

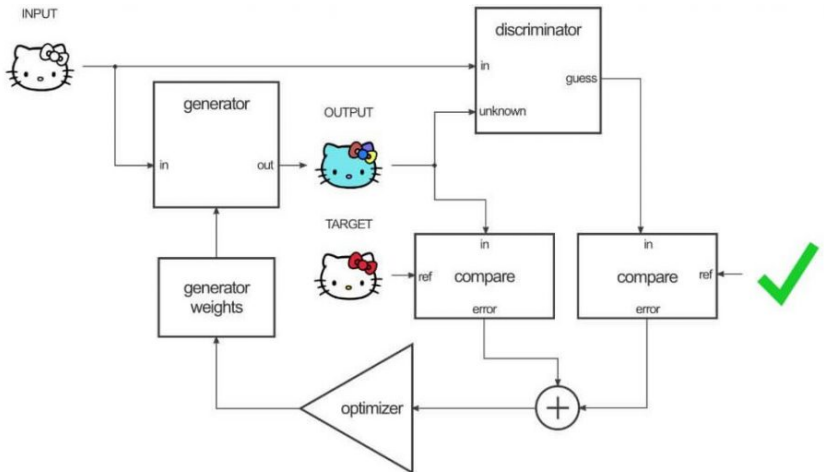

FIGURE 2.1 – Pix2pix 1.3(b)

relation entre une sortie du modèle et le nombre de pixels dans l'image d'entrée. Ceci est appelé un modèle de Patchgan et est soigneusement conçu de sorte que chaque prévision de sortie des cartes de modèle à un 70 70

2.3 Abstraction vers dessin

Après plusieurs expérience décevantes, nous avons choisi d'utiliser un algorithme de détéction de bord nommé "holistically-nested edge detection" (HED) pour traduire nos peinture en dessins détaillées. Cette solution basée sur un modèle d'apprentissage profond permet de résoudre l'ambiguïté lié à la détection des contours et des objets.

A partir de cette sortie notre but est d'extraire le maximum d'élements de l'image en ne gardant que les caractéristiques les plus représentative. Nous avons testé plusieurs méthodes.

Après essais sur le modèle d'apprentissage, il s'avère que la labellisation manuelle reste dans notre cas la plus satisfaisante.

Nous pensons néanmoins que deux méthodes auraient méritées d'être approfondies, celle la segmentation ainsi que l'algorithme de Ramer–Douglas–Peucker. Dans les deux cas, l'avantage majeur est d'épargner la labelisation manuelle.

2.4 Dessin vers peinture

Afin de réaliser la peinture chinoise à partir de la photo, nous avons pensé directement au cyclegan. Lors de nos recherches, nous avons pu constater des exemples de cyclegan générant des peintures du style monet à partir d'une

photo.
Cependant, nos photos sont en noir et blanc étant donné que le pix2pix a donné un plus mauvais résultat avec avec des images en couleurs qu'en noir et blanc (voir figure 2.2).

Entrée donné au pix2pix | Résultat en couleur | Résultat en noir et blanc

FIGURE 2.2 – Résultat pix2pix entraîné avec des photos en couleurs et en noir et blanc.

Chapitre 3

Résultats

- Graphique temps d'apprentissages / exécutions
- Plot d'images

Chapitre 4

Conclusion et Perspectives

Comme nous l'avons évoqué dans la section état de l'art, il est possible d'appliquer efficacement un style donnée à une image, mais pour que le rendu soit crédible, il faut que l'entrée provienne d'une image réaliste. Notre principale difficulté était donc de transformer une abstraction en dessins réaliste. Les résultats présentés montrent que des modèles comme pix2pix permettent de réaliser ce transfert à condition d'avoir un dataset spécialisée (paysage)et appairé. Ainsi plus y a de variation et de disparité dans le dataset, moins la prédiction sera convaincante.

Par ailleurs, nous savons que les RCNNs, grâce aux couches de convolutions, sont capables de détecter les caractéristiques visuelles communes d'un ensemble d'images. Comme le prouve ce travail : https ://medium.com/artists-and-machine-intelligence/perception-engines-8a46bc598d57, il est peut-être possible de générer un représentation abstraite de nos peintures en utilisant ce principe. Il serait alors théoriquement possible d'obtenir des pairs abstractions/peintures, permettant l'entraînement d'un cGAN type "traduction image-image".

Les résultats pourraient être améliorer en augmentant le nombre d'éléments dans le dataset ainsi que le nombre d'epochs.

Bibliographie

[Can86] J. Canny. A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-8(6) :679–698, 1986.

[EHA12] Mathias Eitz, James Hays, and Marc Alexa. How do humans sketch objects ? *ACM Trans. Graph. (Proc. SIGGRAPH)*, 31(4) :44 :1–44 :10, 2012.

[GEB15] Leon A. Gatys, Alexander S. Ecker, and Matthias Bethge. A neural algorithm of artistic style. *CoRR*, abs/1508.06576, 2015.

[hin18] hindupuravinash. The gan zoo. `https://github.com/hindupuravinash/the-gan-zoo/`, 2018.

[IZZE16] Phillip Isola, Jun-Yan Zhu, Tinghui Zhou, and Alexei A. Efros. Image-to-image translation with conditional adversarial networks. *CoRR*, abs/1611.07004, 2016.

[LLM+19] Mengtian Li, Zhe Lin, Radomír Mech, Ersin Yumer, and Deva Ramanan. Photo-sketching : Inferring contour drawings from images. *CoRR*, abs/1901.00542, 2019.

[PLWZ19] Taesung Park, Ming-Yu Liu, Ting-Chun Wang, and Jun-Yan Zhu. Semantic image synthesis with spatially-adaptive normalization. *CoRR*, abs/1903.07291, 2019.

[SBHH16] Patsorn Sangkloy, Nathan Burnell, Cusuh Ham, and James Hays. The sketchy database : Learning to retrieve badly drawn bunnies. *ACM Transactions on Graphics (proceedings of SIGGRAPH)*, 2016.

[SPS+18] Jifei Song, Kaiyue Pang, Yi-Zhe Song, Tao Xiang, and Timothy M. Hospedales. Learning to sketch with shortcut cycle consistency. *CoRR*, abs/1805.00247, 2018.

[Wik20] Wikipedia. Réseaux antagonistes génératifs — Wikipedia, the free encyclopedia. `http://fr.wikipedia.org/w/index.php?title=R\%C3\%A9seaux\%20antagonistes\%20g\%C3\%A9n\`

%C3\%A9ratifs&oldid=170457375, 2020. [Online; accessed 17-May-2020].

[ych18] ychen93. The gan zoo. https://github.com/ychen93/Chinese-Painting-Dataset, 2018.

[ZPIE17] Jun-Yan Zhu, Taesung Park, Phillip Isola, and Alexei A Efros. Unpaired image-to-image translation using cycle-consistent adversarial networks. In *Computer Vision (ICCV), 2017 IEEE International Conference on*, 2017.